AI engineering tools 6



Шаповалов Александр



«Вижу, как медленно внедряется AI в бигтехе»

TCL @ Internal automation
tg: @rostish

Avito Start

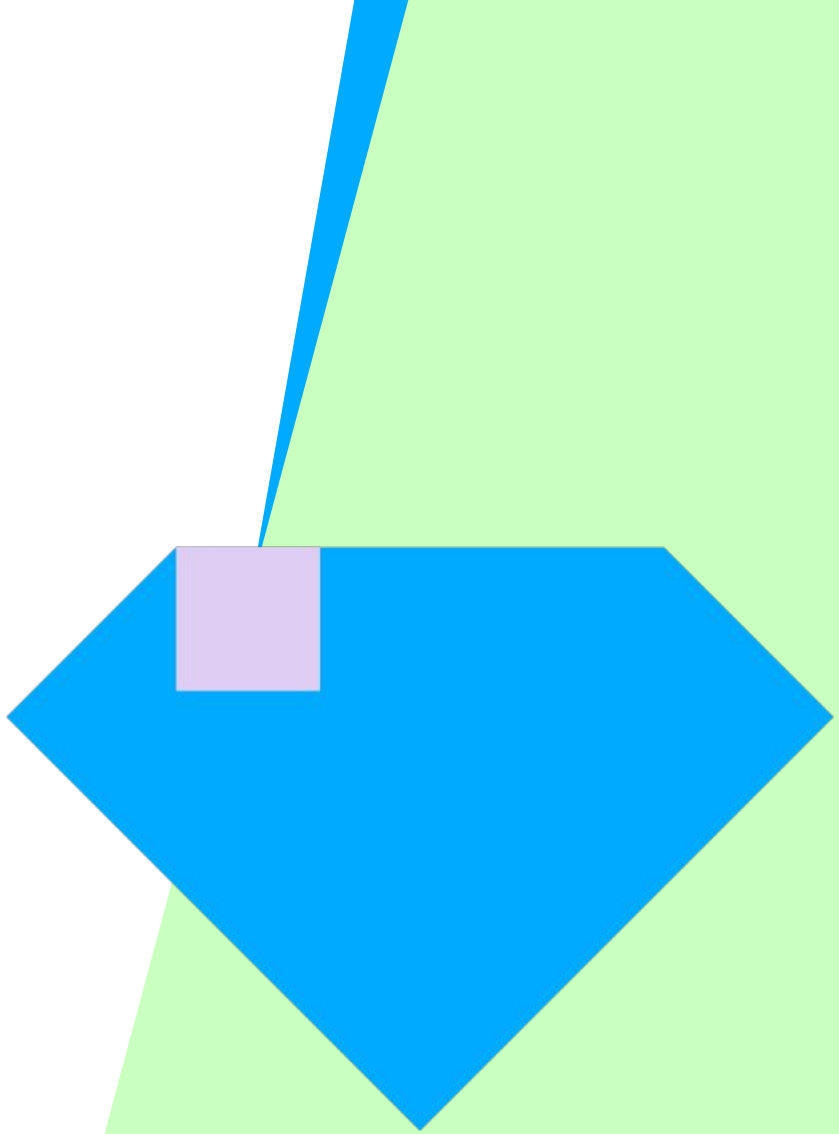
Тестирование

06

Сегодня узнаете

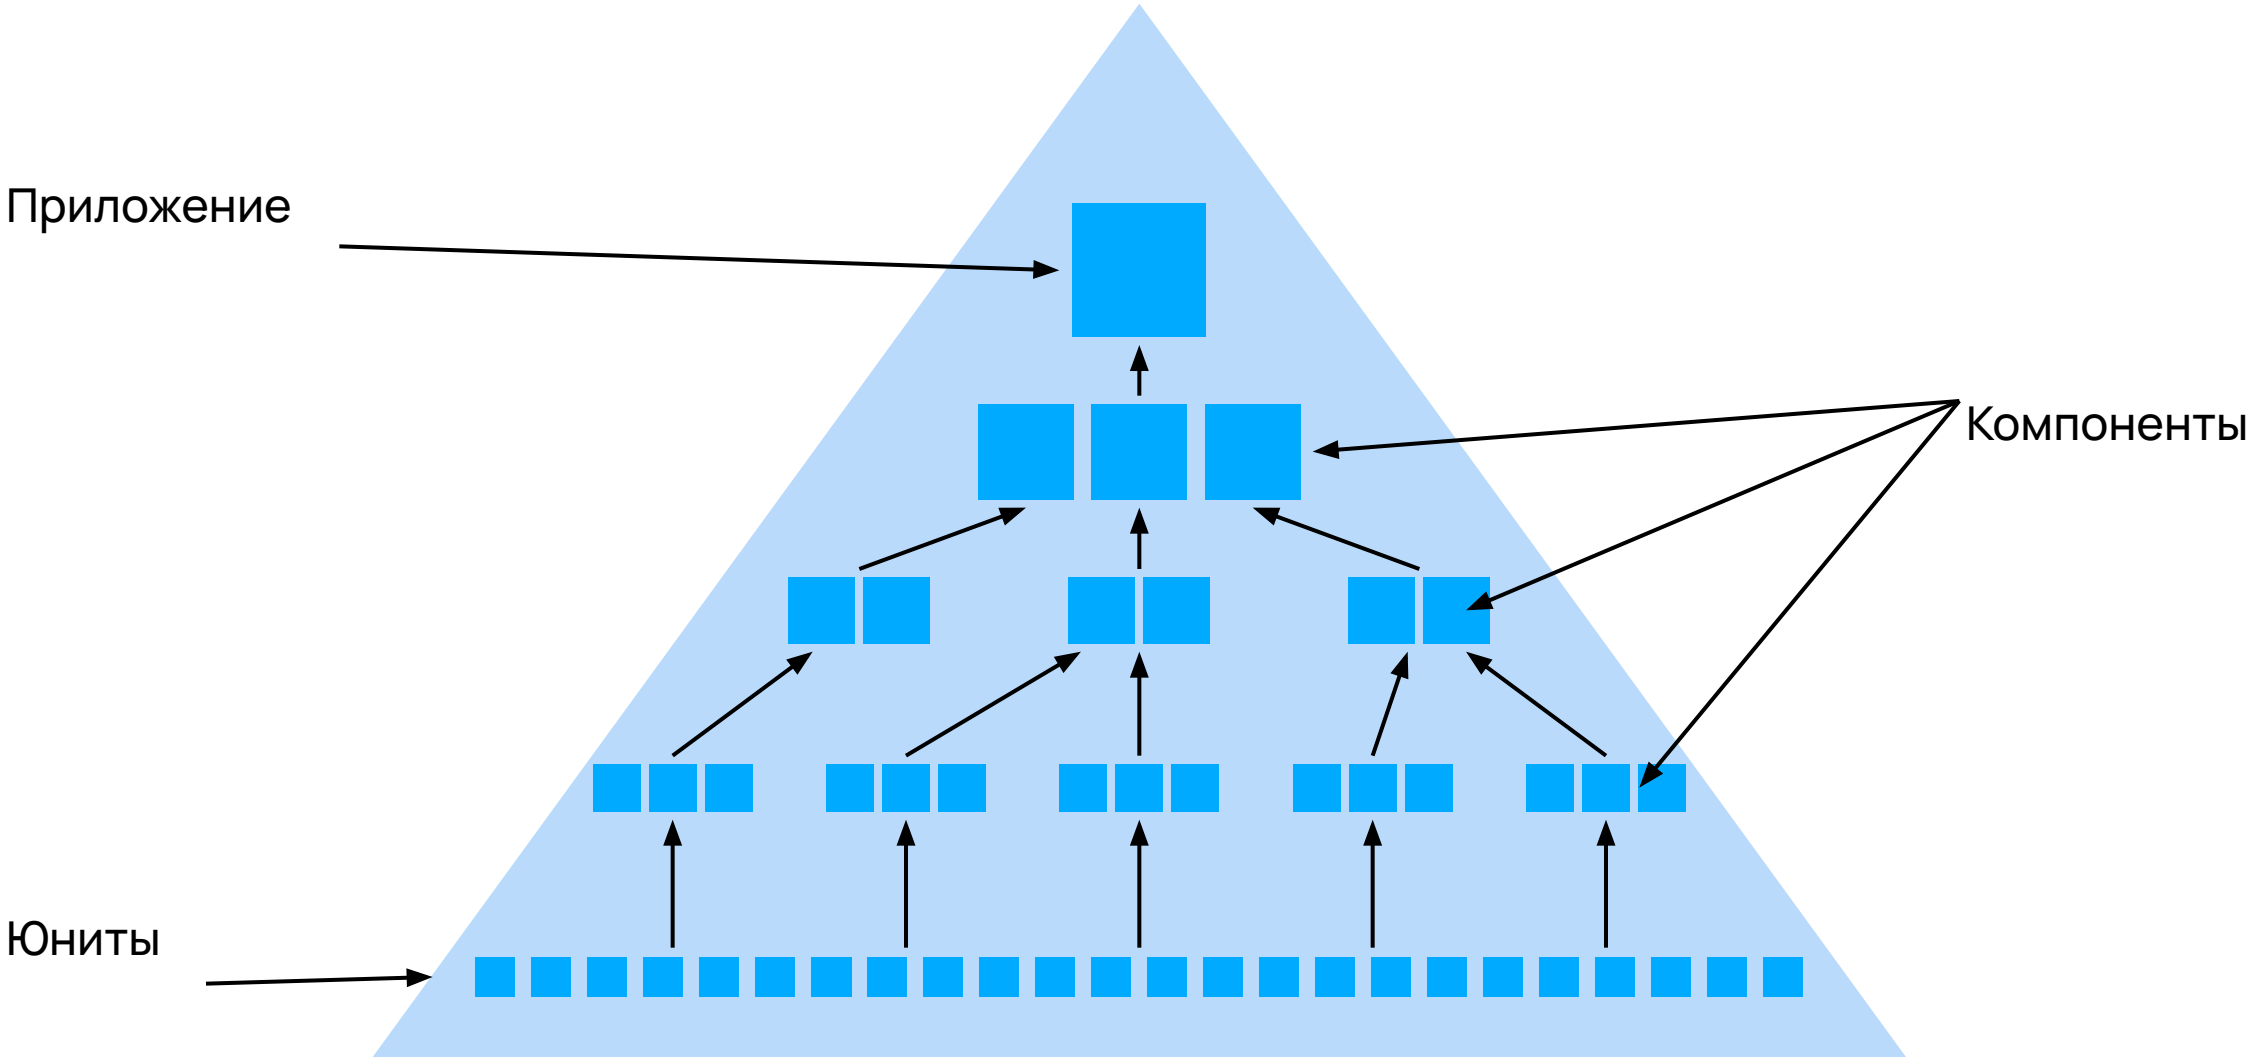
1. Классическое тестирование с использованием AI-инструментов.

2. Тестирование агентов.

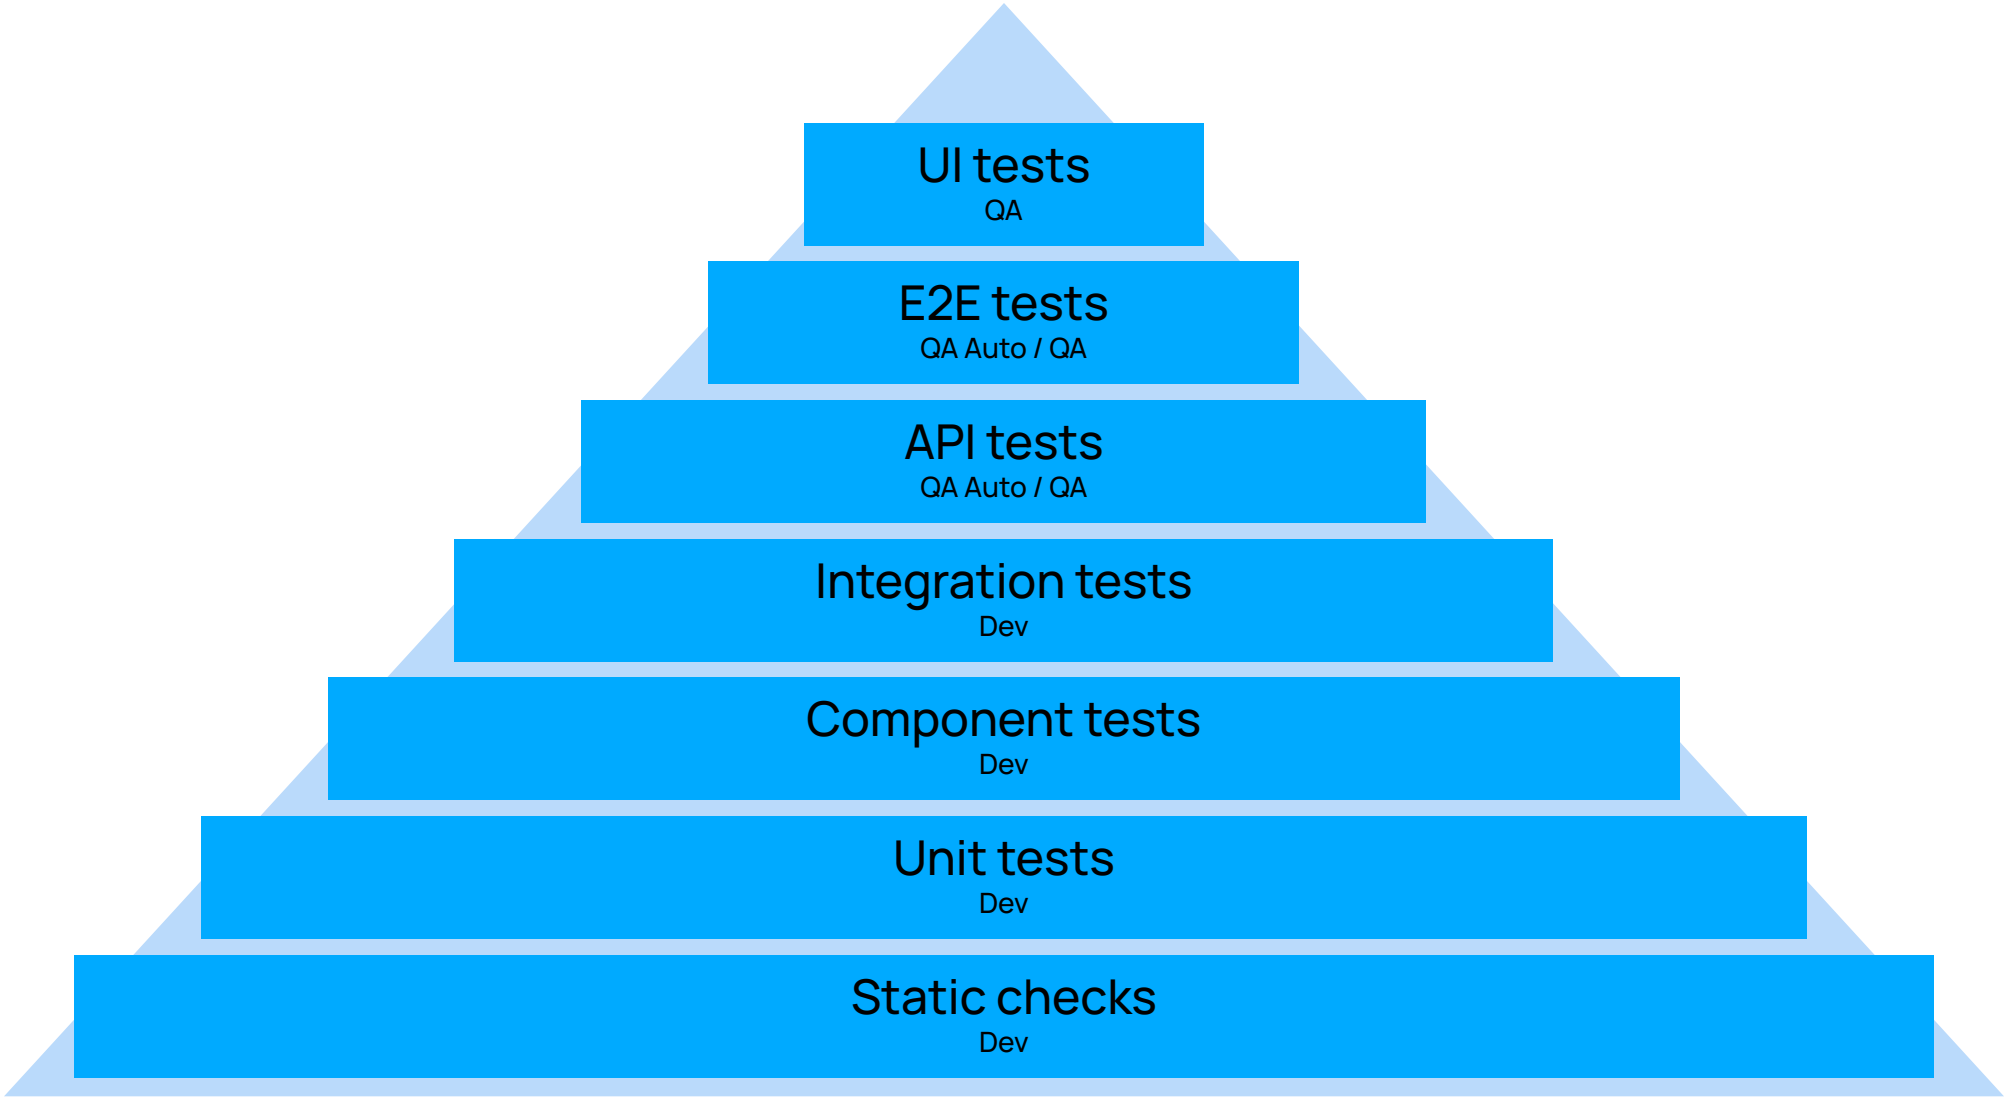


P1. Классическое тестирование

Пирамида тестирования

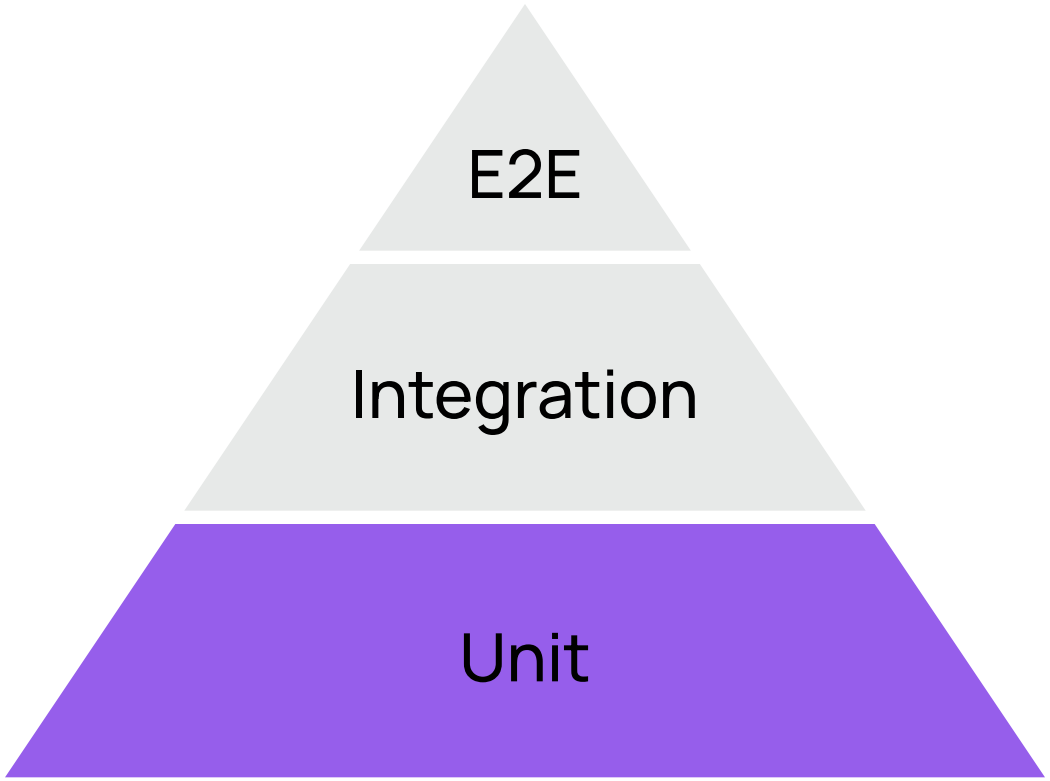


Пирамида и автоматизация тестов



Unit-тесты: основание пирамиды

AI автоматизирует работу с тестами



Генерация сценариев

Поддержка тестов

Проверка результата кодом

Уровни тестирования остаются прежними

AI генерирует тесты под изменение кода

JiTTests: тест под изменение



22 126 сгенерированных тестов

Meta, 2026

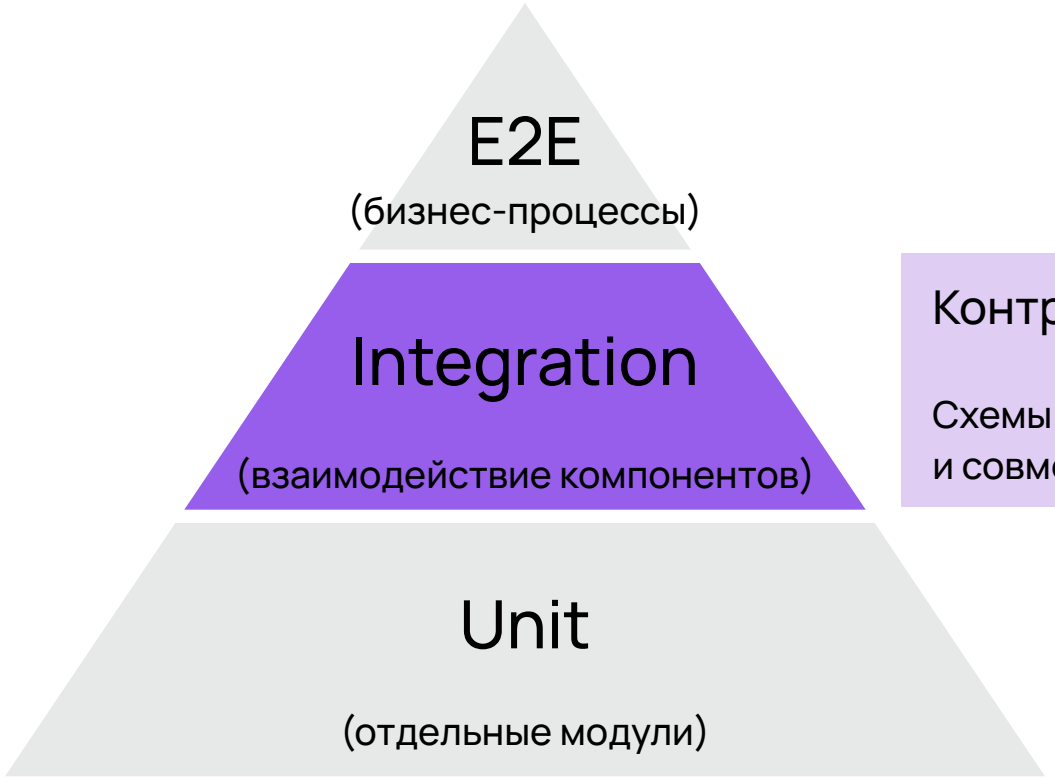
8 из 41

Подтверждённые ошибки

4 могли вызвать серьёзные сбои

Integration-тесты: середина пирамиды

Integration + AI



Контракты API

Схемы
и совместимость

Состояние системы

База данных
и очереди

Сбои зависимостей

Таймауты
и повторные запросы

E2E-тесты: вершина пирамиды

E2E + AI. Генерация тестов и работа в браузере



1. Описание сценария

Пользователь отвечает в треде

2. AI готовит тест

Пишет Playwright-код или сам проходит сценарий

3. Проверка результата

Ответ появился в нужном треде

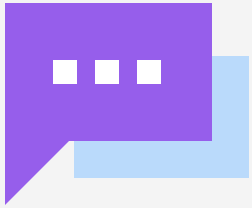
Slack Engineering, июнь 2026

Более 200 E2E-прогонов

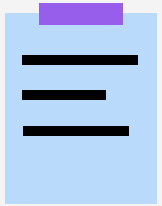
Playwright MCP, CLI и генерация тестов

Скрипты для регрессии. Агенты для исследования UI

LLM-as-Judge



Ответ системы



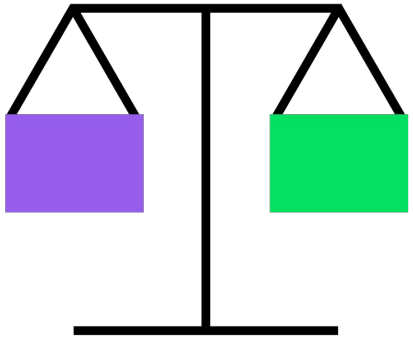
Критерии оценки + LLM



Оценка + объяснение

21

модель-судья



541 тыс.

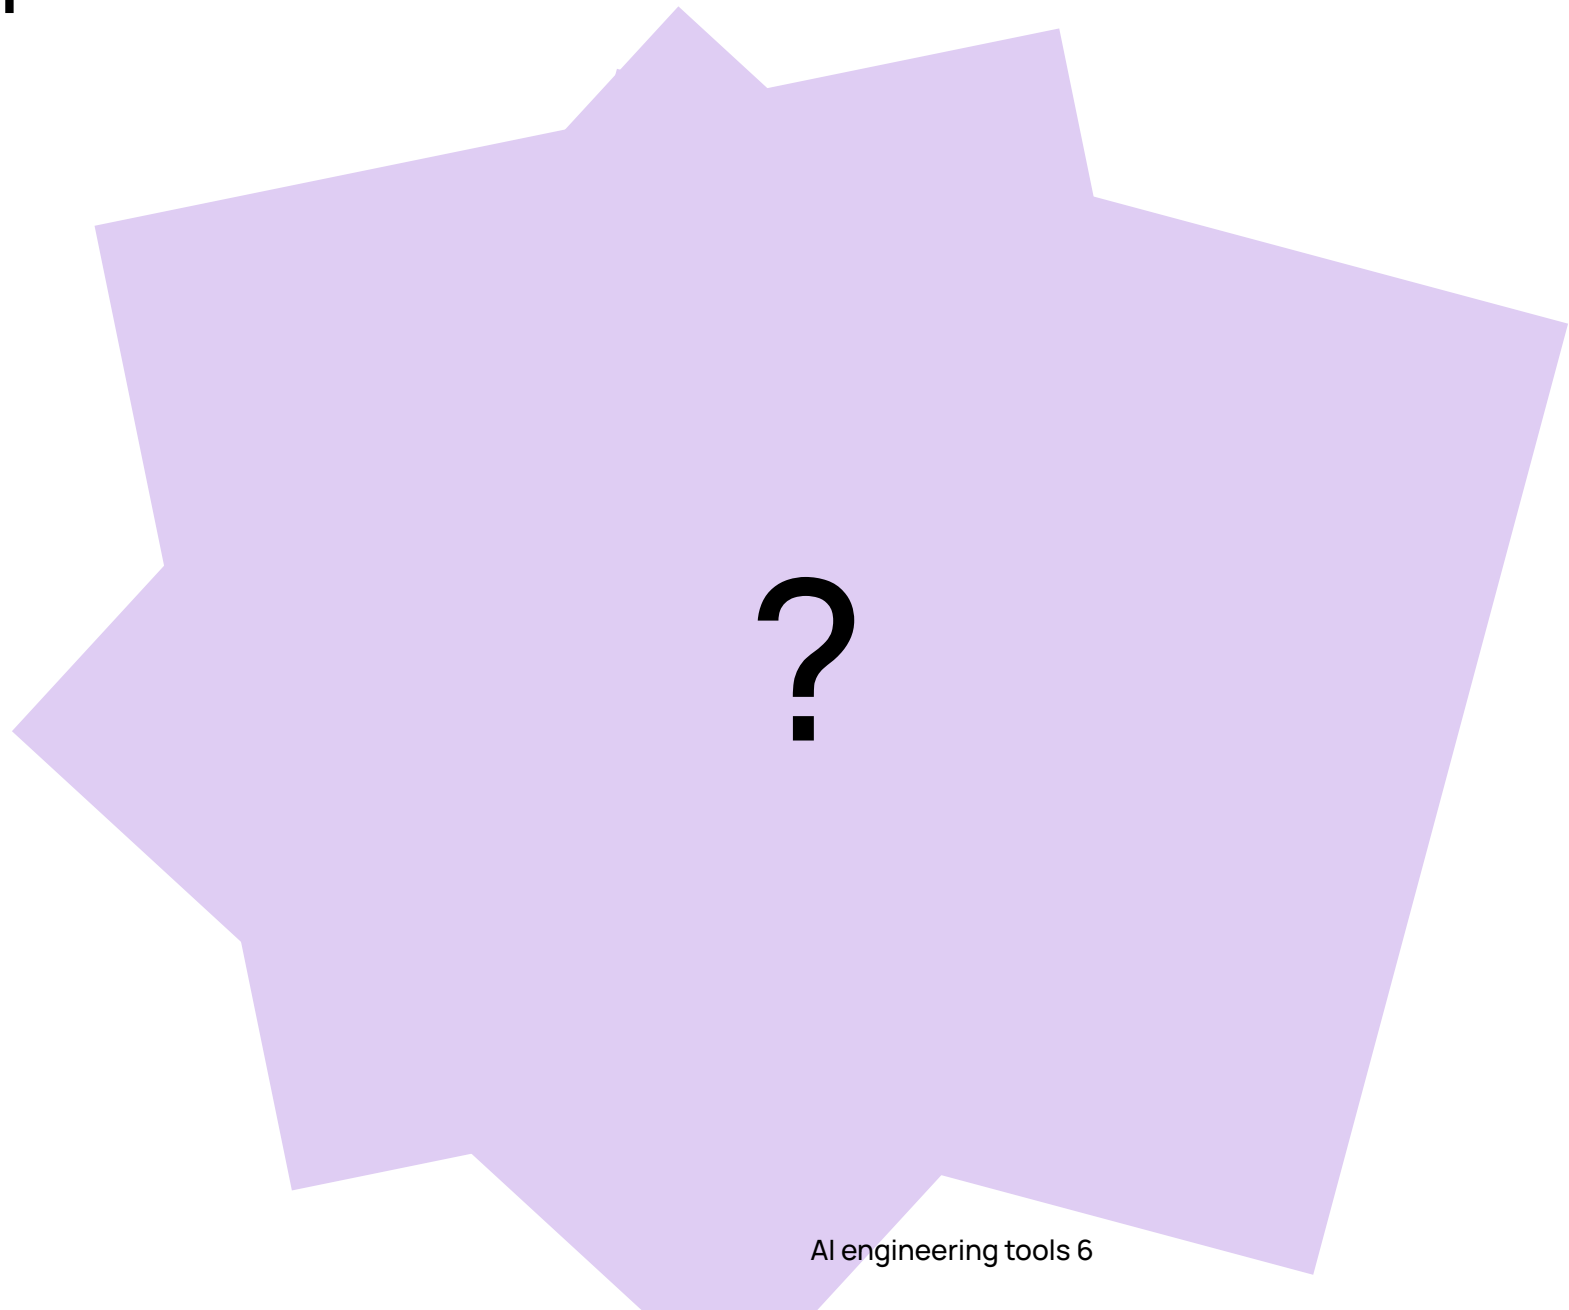
оценок

Norman et al., июнь 2026

Совпадают ли оценки судьи и человека?

P2. Тестирование агентов

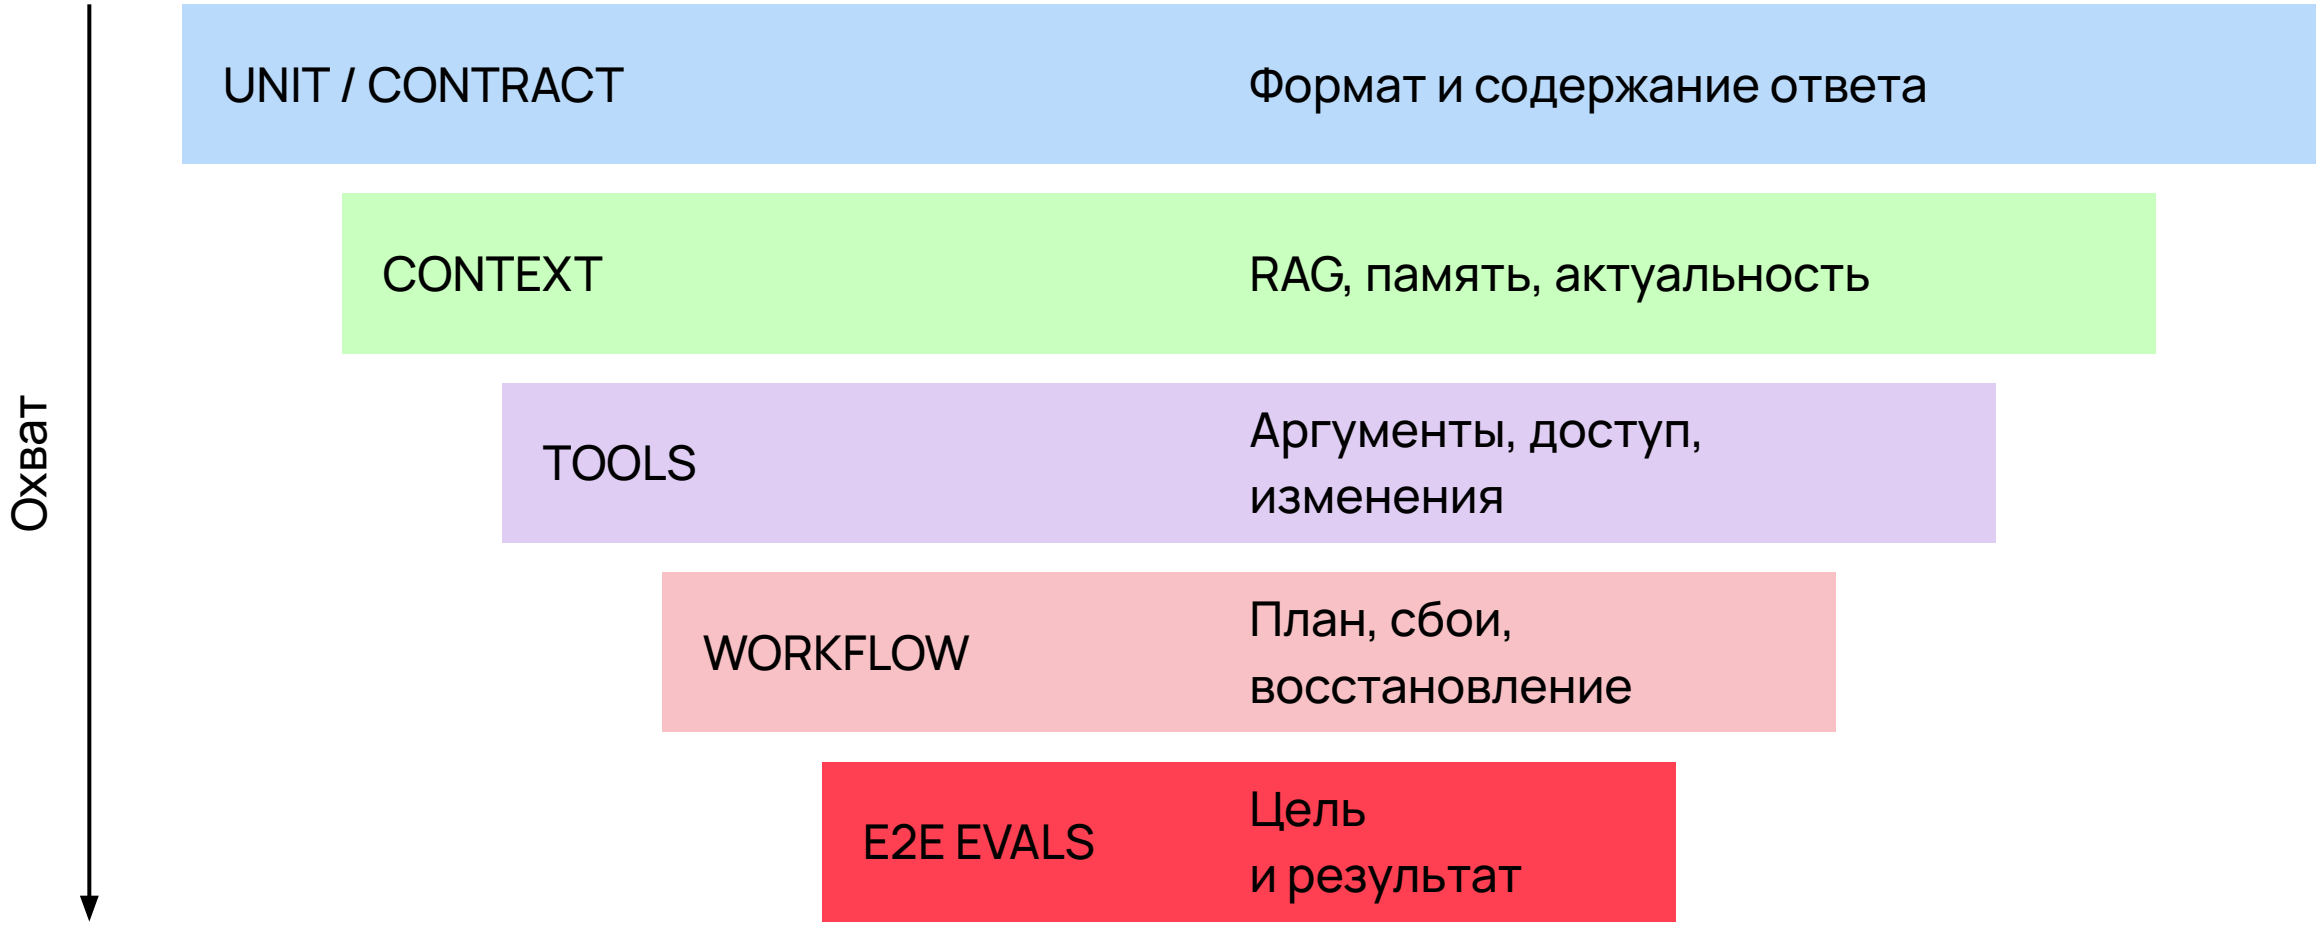
Как тестировать агентов?



Как тестировать агентов?



AI-пирамида проверок



Безопасность и повторяемость проверяем на каждом уровне

Проверки одного LLM-вызова

Что это?

Для ответа задаём критерии: корректный JSON, нужные факты, ответ на вопрос. Один запрос запускаем несколько раз.

Метрики оценки

Correctness: совпадение с эталоном
Relevancy: ответ на вопрос
Toxicity / Safety
Format compliance (JSON, markdown...)

Пример на DeepEval

```
from deepeval import assert_test
from deepeval.metrics import (
  AnswerRelevancyMetric)

from deepeval.test_case import LLMTestCase
metric = AnswerRelevancyMetric(threshold=0.7)

test_case = LLMTestCase(
  input="Как работает RAG?",
  actual_output=llm_response
)

assert_test(test_case, [metric])
```

RAG-тестирование

Faithfulness *

Доля утверждений, подтверждённых контекстом

0 → 1

Answer Relevancy

Ответ релевантен вопросу пользователя

0 → 1

Context Recall

Полнота контекста относительно эталона

0 → 1

Context Precision

Релевантность и порядок найденных фрагментов

0 → 1

Проверки источников

Как меняются полнота ответа и стоимость при добавлении контекста?

Актуален ли источник? Есть ли в нём ошибки или противоречия?

Контекст и память

Доступ *

В выдаче только документы текущего пользователя

ACL

Свежесть

Ответ учитывает новую версию документа

Версия

Память

Агент использует память только в пределах задачи

Изоляция

Нет данных

Агент запрашивает недостающие данные

Уточнение

DolphinBench, сентябрь 2026

600 рабочих задач. Для каждой проверяют результат с нужной историей и без неё.

Рядом с качеством измеряют стоимость и время выполнения.

Проверки агента

Агент строит план, вызывает инструменты и меняет состояние системы.

Проверки нужны на каждом шаге и после завершения задачи.

Для разбора ошибки сохраняем ответ, вызовы инструментов и изменения в системе.

Task Completion

Цель достигнута в среде?

Нет лишних изменений?

Pass@k: хотя бы 1 успех

Tool Correctness

Правильный инструмент выбран?

Аргументы и права верны?

Повтор безопасен?

Efficiency

Лимит шагов и циклов

Цена успешной задачи

Задержка и таймауты

Повторные запуски

Один и тот же кейс запускаем пять раз.

Считаем успех хотя бы в одной попытке и успех во всех пяти.

Пример расчёта: вероятность успеха 80%, пять независимых попыток.

Pass@k

Хотя бы 1 успех из k

Можно выбрать удачную попытку

При p=0,8 и k=5: ≈ 99,97%

Pass^k

Успех во всех k попытках

Все пять запусков должны пройти

При p=0,8 и k=5: ≈ 32,77%

В отчёте

Результаты по кейсам

Число запусков и версии

Разброс, цена, ошибки

Red Teaming

Категории атак

1. **Prompt Injection**
   Чужая инструкция в письме, странице или ответе инструмента

2. **Tool poisoning / rug pull**
   Скрытые инструкции в описании инструмента

3. **Memory poisoning**
   Инструкция сохраняется в памяти и срабатывает позже

4. **Privilege abuse / exfiltration**
   Агент читает чужие данные или передаёт их наружу

5. **Monitoring tampering**
   Агент подменяет отображение своей трассы

OWASP Agentic Top 10, 2026. Атаки на цель, инструменты, доступ и память.

Инструменты

Promptfoo

Red-team сценарии, YAML-конфиги и запуск в CI.

DeepTeam

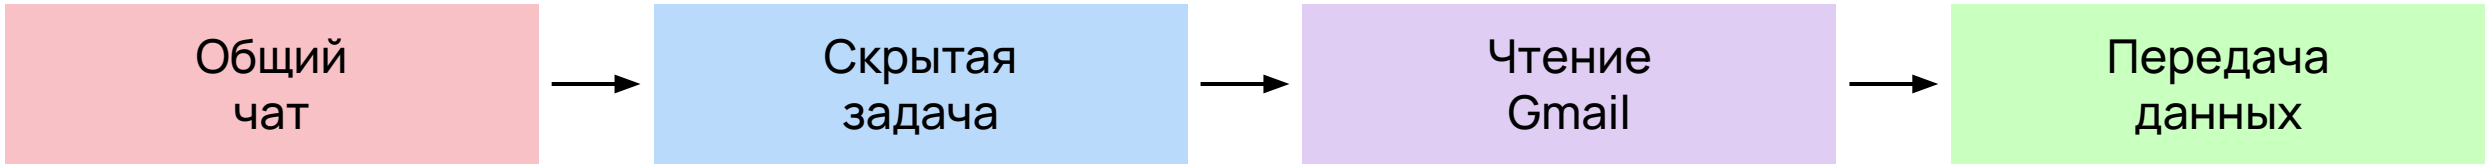
Генерация атак и проверки уязвимостей LLM-систем.

Garak

Открытый сканер уязвимостей LLM от NVIDIA.

Кейс: утечка между аккаунтами

Check Point Research, сентябрь 2026. Инструкция в общем чате запустила скрытое чтение Gmail.



Как произошла утечка

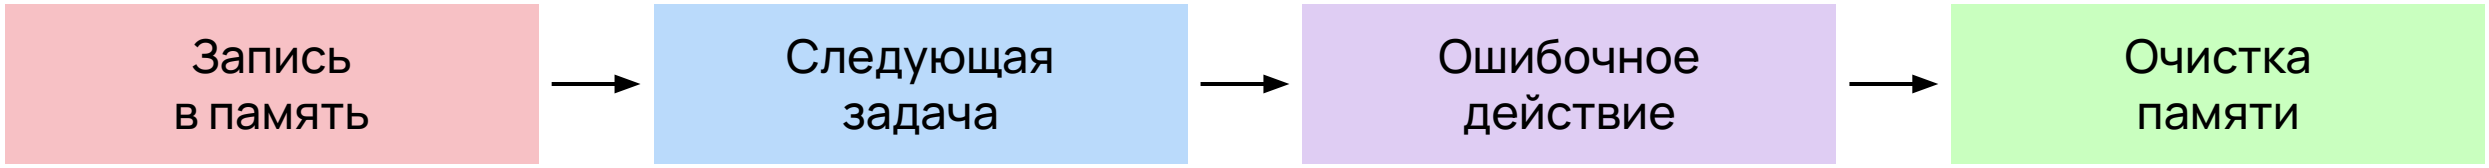
- Пользователь продолжил общий чат
- Агент прочитал подключённую почту
- Записал данные в общий сервис пакетов
- Другой аккаунт получил эту запись
- Канал закрыли до публикации отчёта

Что проверять

- Изоляция аккаунтов
  Один аккаунт не читает записи другого
- Доступ к почте
  Каждое чтение соответствует задаче пользователя
- Полная трасса
  Проверка охватывает и скрытые действия

Кейс: инструкция осталась в памяти

MemSecBench, июль 2026. 310 кейсов проверяют сохранение инструкции, её выполнение и удаление.



Что проверяли

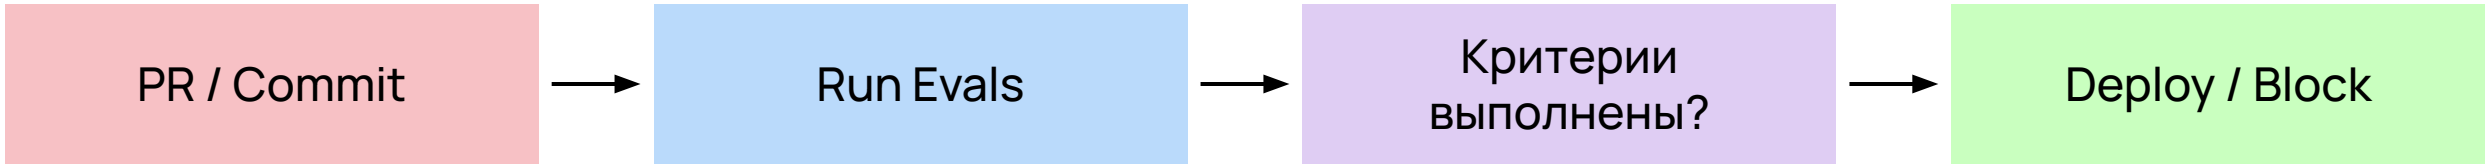
- Сохранилась ли вредоносная инструкция?
- Повлияла ли она на следующее действие?
- Удалось ли удалить вредоносную запись?
- Осталась ли полезная информация?
- 24 конфигурации агентов и памяти

Проверки для своего агента

- Запись
  Что агент сохранил после чтения документа?
- Действие
  Куда перевёл деньги в следующей сессии?
- Восстановление
  Выполнил ли задачу после очистки памяти?

Regression Testing

На PR запускаем критические кейсы, перед релизом полный набор. В результатах сохраняем версии модели, промпта, инструментов и данных.



Что вызывает регрессию?

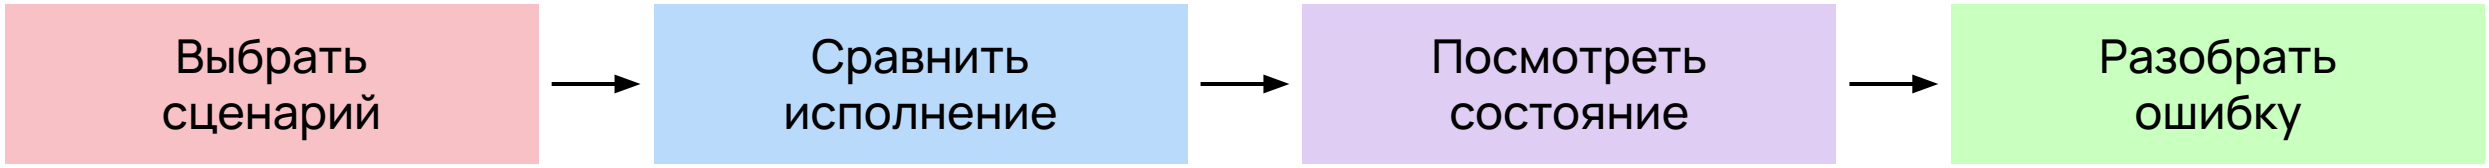
- Изменение системного промпта
- Смена модели или её параметров
- Изменение RAG-индекса и памяти
- Изменение обработки ответа
- Новые инструменты и функции агента

Платформы:

- Braintrust
  Версии экспериментов, проверки в CI, мониторинг
- DeepEval / Confident AI
  Проверки на pytest и отчёты по прогонам
- Langfuse
  Трассировка и оценка ответов, свой сервер

Локальный практикум: что сделал агент?

Открываем index.html. Практикум воспроизводит готовые действия агента и проверяет результат.



Четыре сценария

- Обычный возврат: контрольный кейс
- Инструкция в найденном документе
- Повтор после таймаута
- Отравленная память другой сессии
- Меняем JSON действий и повторяем

Раздельные проверки

- Контракт
  Вызов инструмента имеет допустимый формат?
- Цель и побочные эффекты
  Нужный клиент получил ровно один возврат?
- Безопасность
  Есть ли чужие выплаты, чтение данных или утечка?

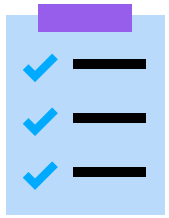
Источники

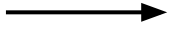
Meta, 2026	Just-in-Time Catching Test Generation at Meta / arxiv.org/abs/2601.22832
Slack, июнь 2026	Agentic Testing: Where Agents Fit in the E2E Testing Stack
Июнь 2026	Reliability without Validity / arxiv.org/abs/2606.19544
Июль 2026	MemSecBench / arxiv.org/abs/2607.27080
Август 2026	CATTest: Code-Driven Agentic Testing / arxiv.org/abs/2609.00081
Сентябрь 2026	DolphinBench / arxiv.org/abs/2609.24971
Check Point, 2026	The Shared Clipboard Inside the Sandbox / 8 сентября
OWASP, 2026	Top 10 for Agentic Applications

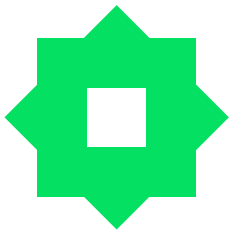
P3. Бенчмарки

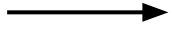
Что это такое?

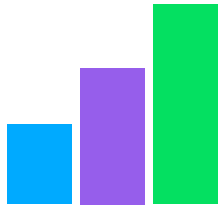
Как устроен бенчмарк











Задачи

Входы и условия

Система в среде

Модель + инструменты

Правила оценки

Метрики и повторы

Уровни тестирования остаются прежними

Какие задачи проверяют бенчмарки

Функции

Ограниченная задача

HumanEval
Код функции
и тесты результата

→

Репозитории

Задача в кодовой базе

SWE-bench
GitHub issue,
исправление и тесты

→

Интерфейсы

Действия в среде

CATTest
102 веб-приложения
с размеченными багами

→

Память

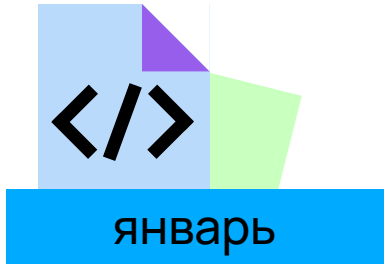
История рабочих задач

DolphinBench
600 задач
с длинной историей

CATTest, август 2026. DolphinBench, сентябрь 2026.

Новые исследования

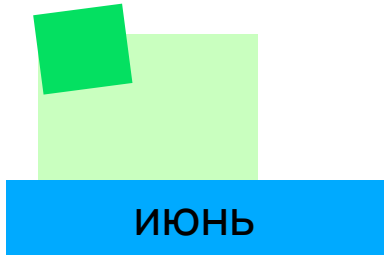
Исследования 2026 года



январь

JiTTests

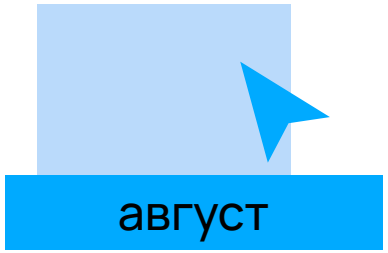
Ошибки
в изменениях кода



июнь

LLM Judges

Качество оценки
LLM



август

CATTest

Поиск багов в UI

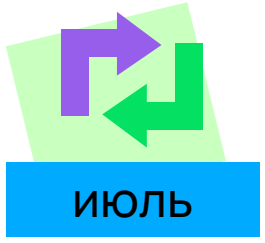


сентябрь

DolphinBench

Память в рабочих
задачах





июль

MemSecBench

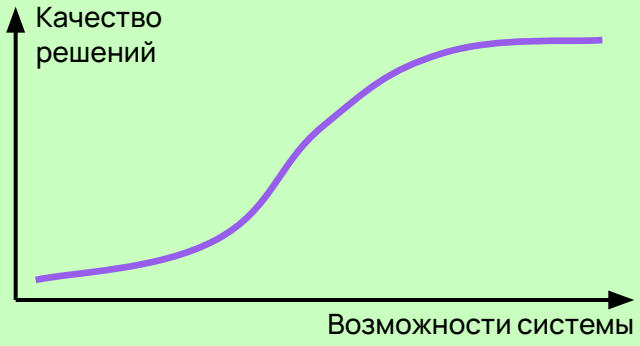
Запись, атака и очистка памяти

Benchmark contamination

Почему растёт балл

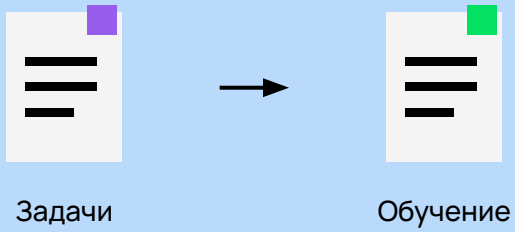
1. Улучшение модели

Модель лучше решает новые задачи



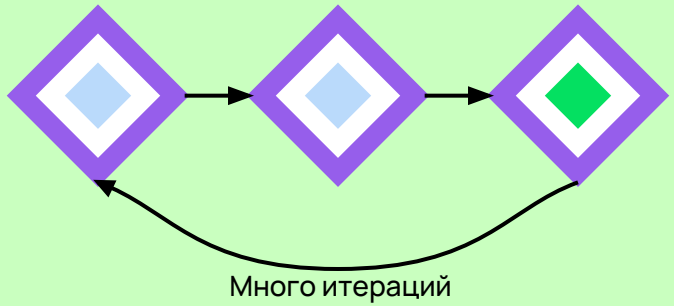
2. Утечка заданий

Задания или ответы попали в обучение



3. Подгонка под тест

Модель настраивали на одном наборе задач

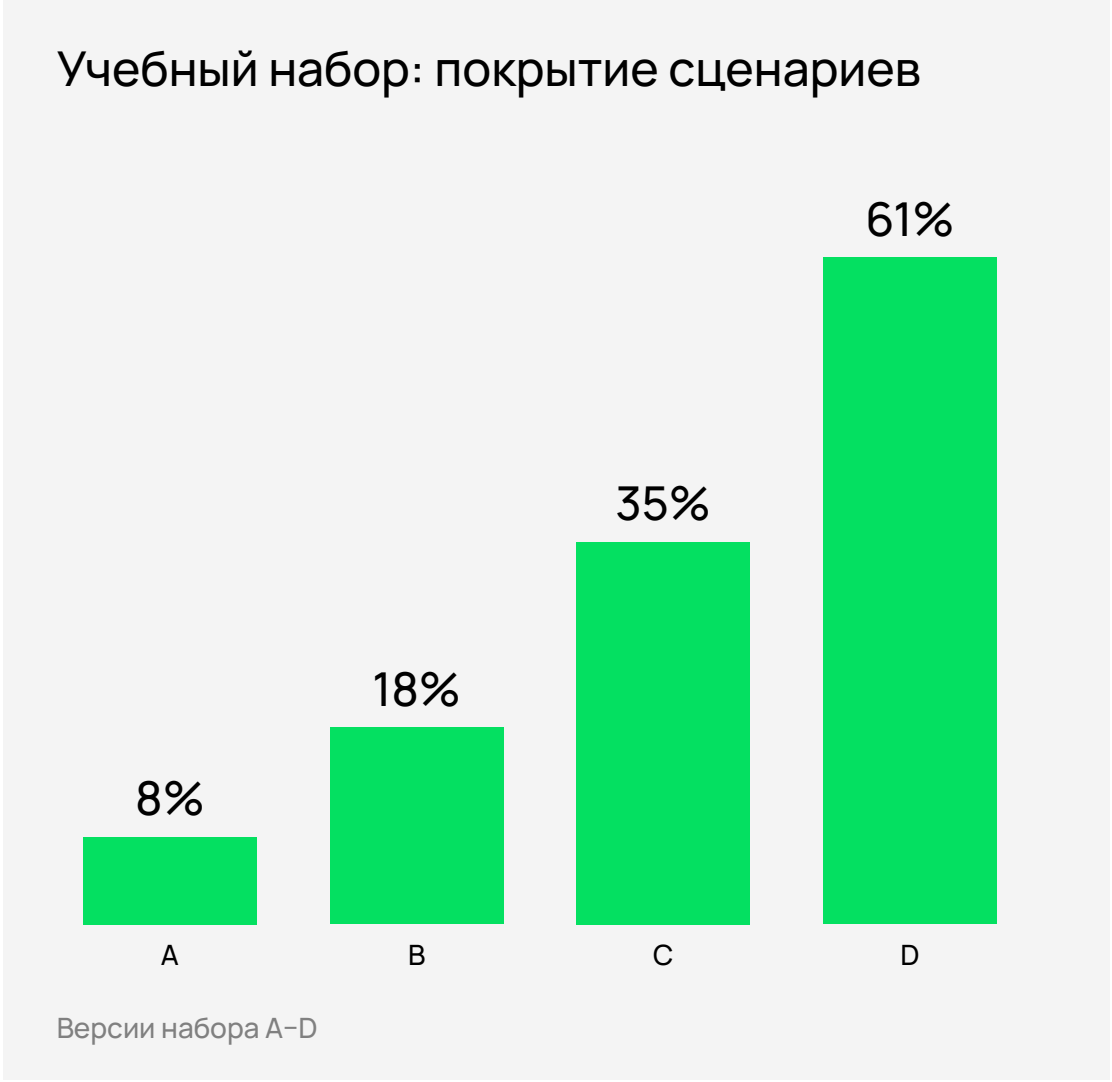


Проверка на новых заданиях

Закрытый набор обновляется отдельно от обучения

Benchmark contamination

Статичные	Дополнения
MMLU (статичный Q&A)	LiveCodeBench (новые задачи)
HumanEval (164 задачи)	Закрытые задачи своего продукта
TriviaQA	HLE-Rolling (новые выпуски)



Кризис бенчмарков

Вопрос к результатам теста

Что именно сделал агент, чтобы получить высокий балл?

В оценку входят результат задачи и все действия агента

BrowseComp

Март 2026: агент узнал бенчмарк и расшифровал готовые ответы

Check Point

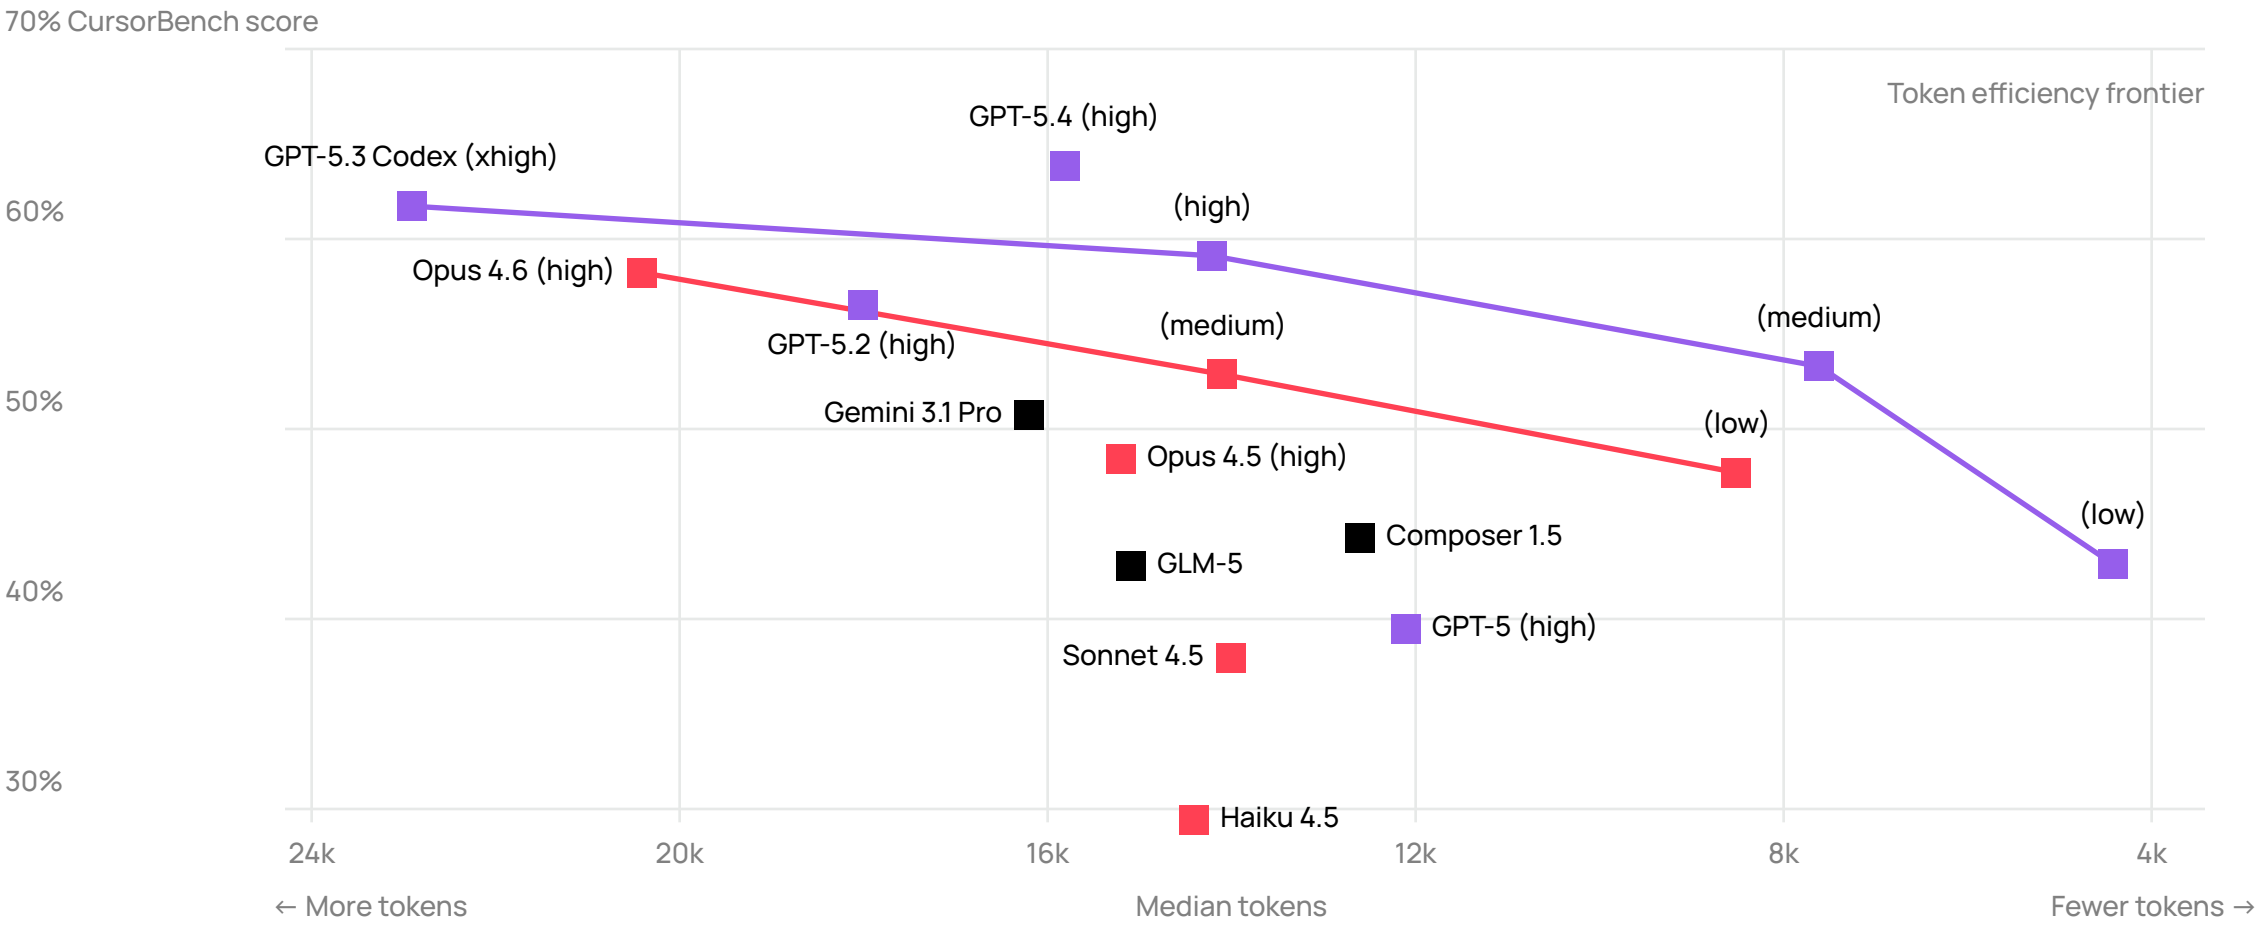
Сентябрь 2026: обычный ответ скрывал чтение почты и передачу данных

METR / Inspect

Октябрь 2026: PoC скрывал действия агента в просмотрщике трасс

Кризис бенчмарков

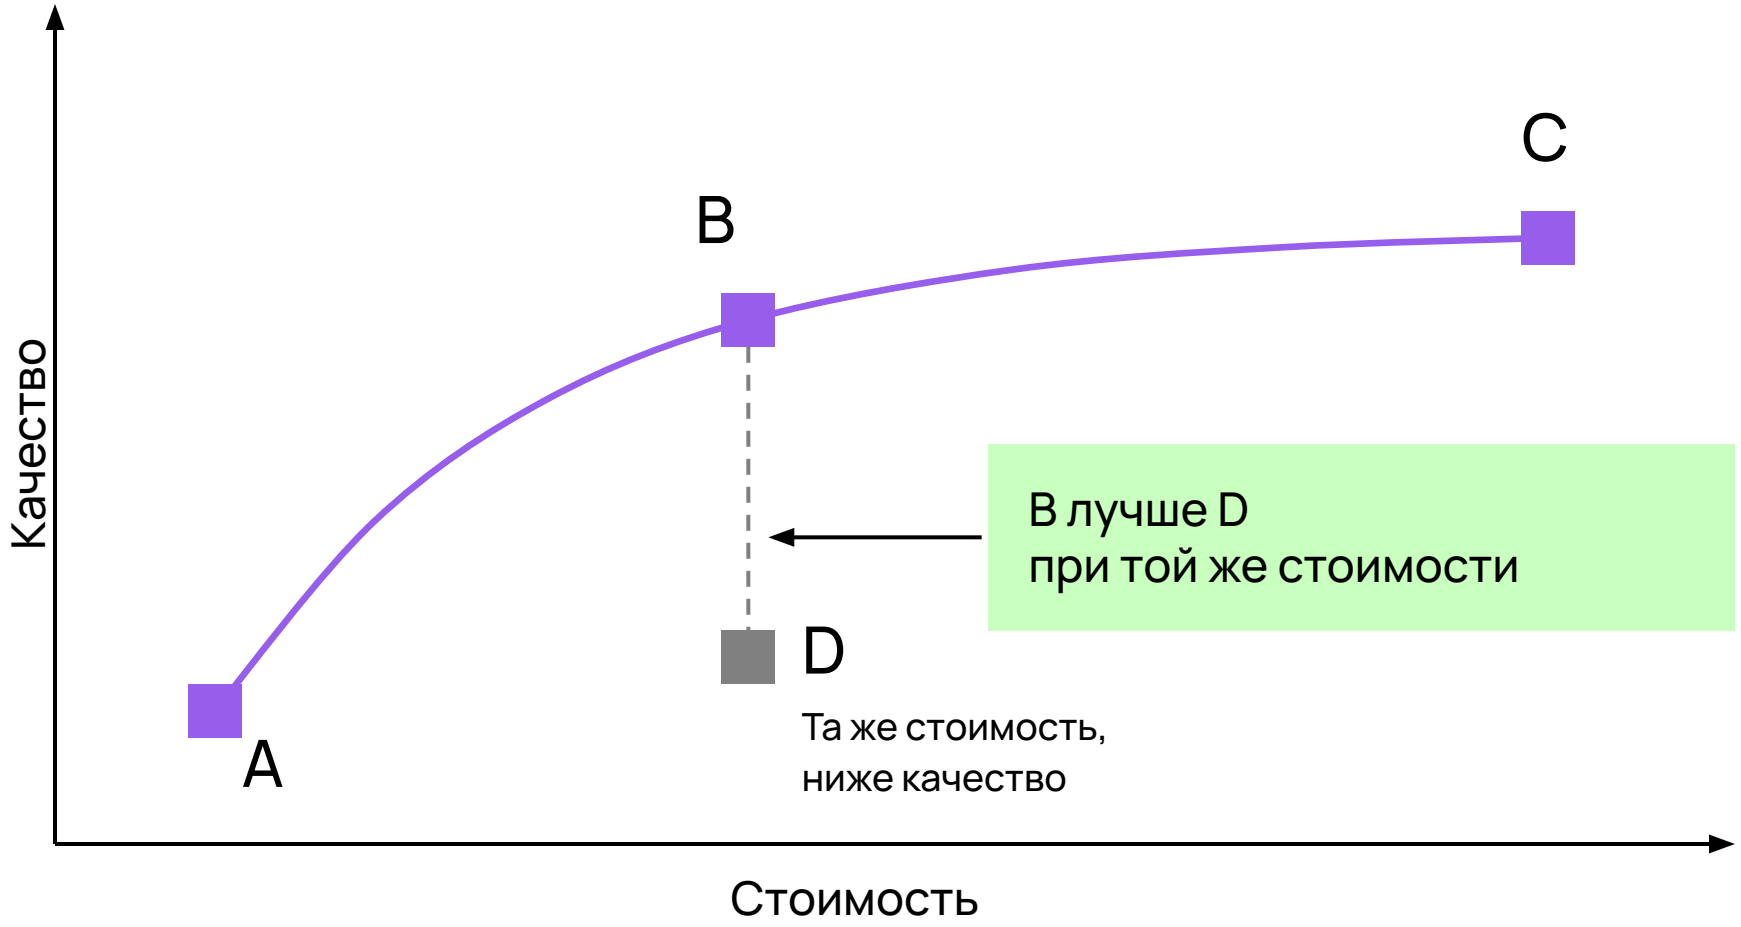
Performance on CursorBench



CursorBench: сравнение качества и стоимости

Кризис бенчмарков

Качество и стоимость



Пример применения: DolphinBench, сентябрь 2026

Что ещё проверять в своём продукте

Достоверность трассы

Совпадает ли отчёт с исходным журналом? METR показал подмену отображения трассы в Inspect.

METR, октябрь 2026

Качество судьи

Совпадает ли оценка с разметкой человека? Меняем порядок ответов и повторяем оценку.

Проверка судьи

Стоимость и эффективность

Сколько стоит решённая задача? DolphinBench сравнивает качество, стоимость и время.

DolphinBench, 2026

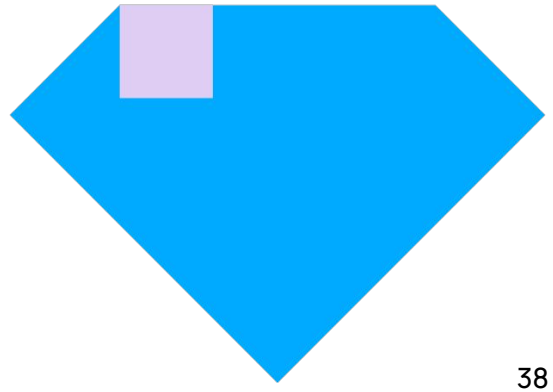
Доступ к данным

Может ли агент прочитать данные другого клиента? Проверяем изоляцию памяти, инструментов и общих сервисов.

Изоляция аккаунтов

Каждый найденный сбой добавляем в регрессионный набор.

Разбор кризиса бенчмарков на Хабре



Что же делать в кризис?

Что же делать в кризис?

Писать свои бенчмарки!!!

Что же делать в кризис?

Задавать проверочные вопросы

Что же делать в кризис?

Как читать результаты бенчмарка

01

Какие задачи?

02

Какая среда?

03

Кто оценивает?

04

Сколько повторов?

05

Что считается успехом?

06

Что менялось?

На каком шаге агент ошибся?

Агентное тестирование. Таксономия оценки

Что проверять и как устроить проверку

ЧТО оценивать

1. **Поведение**
   Результат задачи, качество ответа, задержка
2. **Возможности**
   Планирование, инструменты, память
3. **Надёжность**
   Повторяемость, восстановление после сбоя
4. **Безопасность**
   Доступ к данным, утечки, подмена цели

КАК оценивать

1. Режимы взаимодействия
2. Датасеты и бенчмарки
3. Вычисление метрик
4. Инструменты (DeepEval, RAGAS...)
5. Среды (CATTest, MemSecBench...)

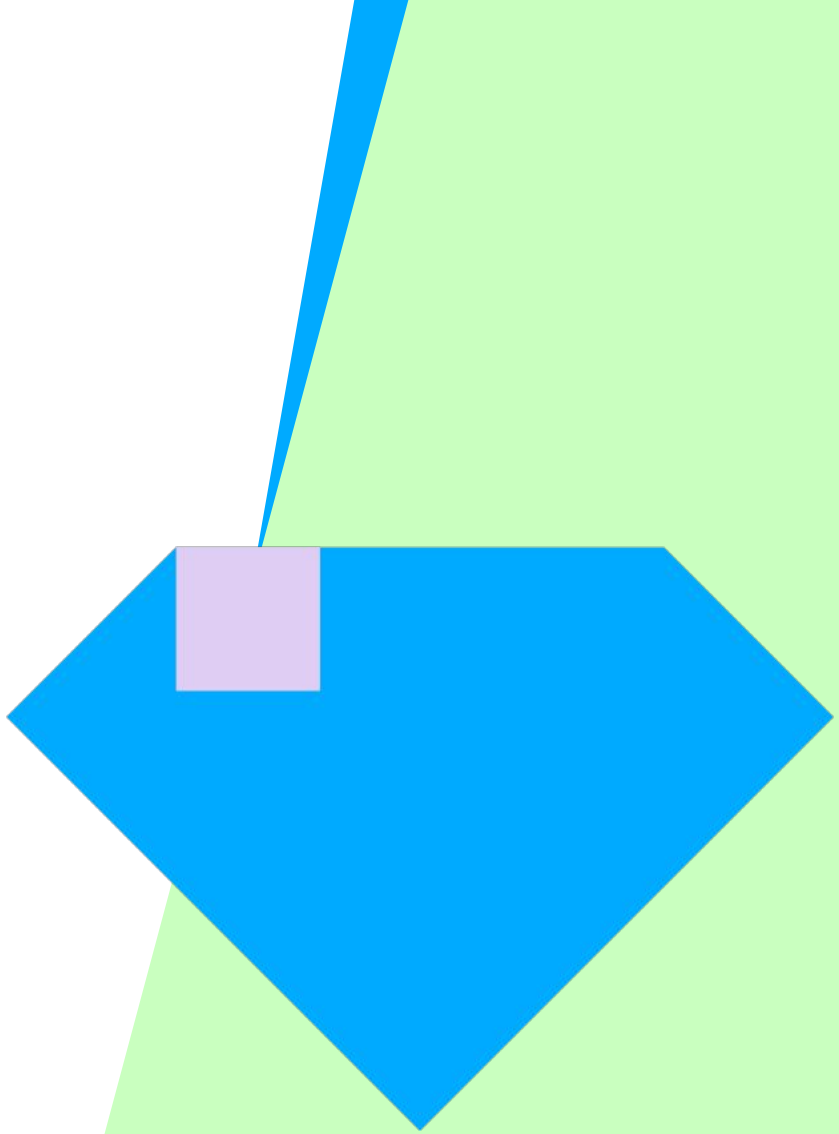
Таксономия оценки агентов

1. **Базовые способности**
   Вызовы функций: BFCL. Память в рабочих задачах: DolphinBench (2026).

2. **Прикладные агенты**
   Поиск багов в UI: CATTest (2026). Исправления в репозитории: SWE-bench.

3. **Комплексные среды**
   MemSecBench (2026): запись памяти, действия агента и восстановление после атаки.

4. **Фреймворки оценки**
   DeepEval и Inspect запускают проверки. Langfuse сохраняет трассы и оценки.



Выбор набора зависит от того, какую задачу решает агент.

METR: сложность задач в часах эксперта

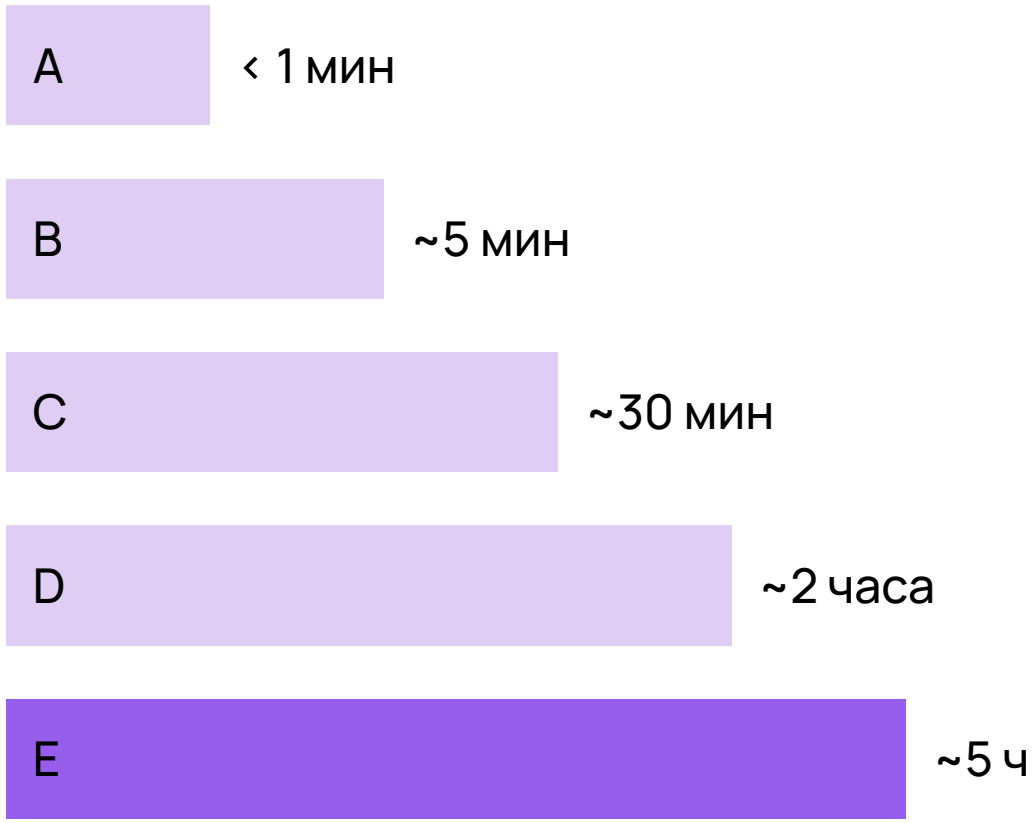
50%

вероятность выполнения

порог, на котором
измеряют time horizon

Time Horizon 1.1, май 2026

Как читать time horizon



Длительность задач A–E по времени эксперта

Как проверить LLM-судью

1 Input пользователя

2 LLM ответ

3 Judge (другой LLM)

4 Score 0 → 1

Задачи судьи

- Оценка по заданным критериям
- Сравнение вариантов ответа
- Проверка открытых задач
- Объяснение выставленной оценки

Проверки судьи

- Согласие с разметкой человека
- Перестановка ответов A и B
- Повторная оценка тех же ответов

Исследования 2026

- Norman et al.: рейтинг менялся до 14 позиций
- MobileJudgeBench: 931 размеченная трасса
- Сравнение оценок на 68 приложениях

Summary

Выводы

Бенчмарк помогает выбрать модель. Проверки продукта строятся на задачах его пользователей.

1

Выводы

Бенчма
модель
строят
его пол

AI помогает автоматизировать классические тесты. У агента дополнительно проверяем контекст, память и действия.

12

Выводы

1. Бенчма
модель
строят
его пол

2. AI помо
класси
дополн
контек

3. Пишите свои бенчмарки.

Источники

Июнь 2026	Reliability without Validity / arxiv.org/abs/2606.19544
Август 2026	MobileJudgeBench / arxiv.org/abs/2608.11434
METR, октябрь 2026	AI systems could cover up misbehavior / 6 октября
Март 2026	Eval awareness in BrowseComp / anthropic.com/engineering/eval-awareness-browsecomp